


胡畅

男 | 年龄: 31岁 | 15914486664 | 1223966468@qq.com

5年工作经验 | 求职意向: AI应用开发工程师 | 期望城市: 深圳



个人优势

- 全栈 AI 工程化能力: 从 Java 后端转型 AI 方向, 具备从数据清洗、检索增强到效果评测的完整 RAG 管线构建经验, 能独立主导 AI 项目从零到一落地
- 架构设计能力: 擅长系统解耦和模块化设计, 在 Agent 记忆系统和 RAG 系统中多次实践三层解耦架构, 各层独立部署、独立迭代
- 问题驱动的技术选型: 根据实际场景做判断——如 RAG 场景选指令跟随型模型而非推理型模型, 记忆系统选工具自治范式而非规则引擎
- 闭环思维: 不止关注功能实现, 同时建立评测和监控体系 (知识采集→消费闭环、三层评测体系), 保证系统可衡量、可迭代
- 自驱学习与实践: 个人项目从零实现了完整的 Agent 记忆系统, 涵盖向量检索、MCP 协议集成、工具热插拔等, 将前沿技术转化为可运行方案

工作经历

深圳市爱德泰科技股份有限公司

ai 应用工程师

2026.04-2026.05

内容:

负责企业 IT 运维知识的自动化沉淀与消费体系建设。基于 Dify 平台构建了知识采集和知识问答两个独立工作流, 通过 LangBot 长连接对接企业微信智能机器人, 形成知识闭环。

业绩:

- 实现了知识采集到消费的自动化闭环, 采集机器人的输出直接成为问答机器人的检索源, 消除了人工整理知识库的环节
- 通过多模态模型将客服截图自动转化为结构化知识条目, 替代了人工逐条录入
- 构建了多分支意图分类 + 多轮反问澄清的问答流程, 覆盖了模糊咨询场景, 避免答非所问
- 入库前自动脱敏处理, 保证企业信息安全合规

深圳英威腾电气股份公司

java

2021.05-2025.10

内容:

前期负责 Java 后端开发, 参与企业级业务系统的设计、开发和维护, 积累了服务端工程化经验。后期随着企业 AI 转型需求, 主导了企业文档 RAG 检索增强系统的建设——面向内部多格式混乱文档 (PDF 扫描件、DOCX、PPTX 等), 构建了从数据清洗到检索增强到效果评测的完整 RAG 管线。

业绩:

- 从 Java 开发转型 AI 方向, 独立主导了企业文档 RAG 系统的从零建设
- 一套管线统一处理多种异构文档格式, 语义分块提升了不同格式文档的检索一致性
- 混合检索 + 重排序策略减少了单一检索方式的漏召回
- 建立三层评测体系, 明确了 RAG 评测中自动化与人工的合理分工边界

项目经历

企业知识采集与问答双机器人系统

AI 应用开发工程师

2026.04-2026.05

内容:

技术栈： Dify 平台 / 通义千问 qwen-plus / 多模态视觉模型 / LangBot / 企业微信 / 混合检索 + 重排序

项目背景：

企业 IT 运维场景中，客服日常处理大量重复性问题，但解决问题的知识散落在聊天记录中，无法沉淀复用。传统做法需要人工将聊天记录整理成知识库，效率低且滞后。需要一个自动化的知识采集和消费闭环。

架构设计：

基于 Dify 平台构建两个独立工作流，通过 LangBot 长连接对接企业微信智能机器人，形成知识采集与知识问答的闭环。采集机器人负责知识的自动化沉淀——将客服对话转化为结构化知识条目写入知识库。问答机器人负责知识的消费——基于自建知识库提供精准回答。两个机器人独立运行，通过 Dify 知识库 API 共享数据，采集机器人的输出直接成为问答机器人的检索源，无需人工中转。

项目流程：

采集流程：用户在企微中发送客服聊天截图 → 多模态视觉模型识别对话中的系统问题、根因分析和解决方案 → 自动推断所属业务系统 → 输出结构化 Q&A 对。提取结果先缓存在对话变量中，用户审核确认后通过 API 写入 Dify 知识库。入库前自动进行信息脱敏处理（身份证号、手机号、工号等）。支持用户追加修改后重新提交确认。

问答流程：用户提问 → 问题分类器进行意图识别，按 5 种场景分支路由。当用户提问模糊（未指明具体系统）时，反问用户澄清系统名称，将补充信息与原始问题拼接后进行二次检索，实现多轮对话中的需求澄清。多轮上下文通过 Dify 对话变量缓存（上一轮系统名和问题），回答完成后自动清理，不依赖外部存储。检索策略以采集机器人沉淀的 Q&A 知识库为主、企业系统操作文档为辅，双路混合检索加重排序，LLM 基于检索上下文生成回答并自动拼接去重后的引用来源。

业绩：

实现了知识采集到知识消费的自动化闭环，采集机器人的输出直接作为问答机器人的检索源，消除了人工整理知识库的环节

通过多模态视觉模型将客服截图自动转化为结构化知识条目，替代了人工逐条录入

构建了 5 分支意图分类 + 多轮反问澄清的问答流程，覆盖了模糊咨询场景，避免了"答非所问"

通过对话变量实现多轮上下文管理，轻量无外部依赖，维护成本低

入库前自动脱敏处理，保证了企业信息安全合规

检索回答附带来源引用、禁止编造，可追溯可验证

个人agent助手

AI应用开发

2026.01-2026.04

内容：

技术栈： Python / LangGraph / FAISS / Redis / MCP 协议 / FastAPI / DeepSeek / BGE Embedding

架构设计：

采用三层解耦架构解决耦合问题。底层是 RAG 记忆服务，基于 FAISS 向量索引存储长期记忆，独立部署在 8002 端口。中间层是 MCP 协议网关，将记忆的增删改查封装为标准工具接口，独立部署在 8001 端口，遵循 MCP SSE 协议规范。上层是 Agent 推理引擎，通过 MCP 客户端连接网关，以工具调用方式访问记忆服务。三层之间仅通过 HTTP/MCP 协议通信，互不依赖实现细节。核心设计原则是"Agent 无状态，状态在外部"——Agent 进程本身不存储任何用户数据，所有上下文通过工具从外部服务获取。会话记录存在 Redis，长期记忆存在 FAISS 向量库，Agent 可随时销毁重建，靠 user_id 和 session_id 恢复全部上下文。这与 HTTP 无状态设计同构，天然支持水平扩展。

项目流程：

记忆注入流程：新对话启动时，Agent 自主查询当前会话状态，判断是否需要从长期记忆库检索相关信息注入系统提示词，而非由规则引擎预设检索时机。记忆提取流程：对话结束后，LLM 分析完整对话生成候选记忆 → 向量相似度去重（阈值 0.85）→ 同类别 top-3 冲突判断（识别重复/新增/更新三种关系）→ 落库。冲突更新不静默覆盖，需经审批确认。短期记忆管理：Redis 热数据 + 磁盘 JSON 兜底，滑动窗口按轮裁剪，保留完整工具调用历史以支持多轮推理。能力扩展：外部工具注册到独立向量库，Agent 通过语义检索按需发现和加载，新增工具只需定义注册，无需修改提示词。

业绩：

设计了三层解耦架构，将记忆存储、工具网关、Agent 推理拆分为独立服务，各层可独立部署、独立扩缩容、独立升级，解决了记忆逻辑与推理逻辑的耦合问题

实现了"Agent 无状态"范式，Agent 进程不持有任何用户数据，上下文全部外置，进程可随时销毁重建，架构天然支持水平扩展

构建了完整的长期记忆提取管道：候选提取 → 向量去重 → 冲突判断 → 持久化，通过审批机制而非静默覆盖处理冲突更新，保证记忆一致性

设计了工具自治机制——Agent 自己判断何时检索记忆、何时发现新能力，系统只提供真实世界信息不做预设决策，新增工具热插拔零改动提示词

集成了 MCP 多服务协议，支持外部工具自动发现。

智能技服辅助系统

AI应用开发工程师

2024.05-2025.10

内容:

技术栈： Python / mineru / Milvus / BGE Embedding / BM25 + 向量混合检索 / BGE-Reranker / 通义千问 / FastAPI

项目背景:

企业内部存在大量格式混乱的文档——PDF 扫描件、DOCX 操作手册、PPTX 培训材料等，格式不统一导致传统检索方案需要大量人工整理。同时，RAG 系统的效果评估缺乏标准方法：纯粹人工评估成本高，纯粹自动评估又无法判断检索结果和回答的真实质量。

架构设计:

构建了从数据清洗到检索增强到效果评测的三层 RAG 管线。数据清洗层负责将多格式文档统一转化为结构化文本块。检索增强层负责高效的混合检索和基于上下文的答案生成。评测层建立三层体系做持续质量监控。三层各自独立迭代，清洗层输出作为检索层的输入，检索层日志作为评测层的数据来源。

项目流程:

数据清洗：mineru 统一处理 PDF/DOCX/PPTX/扫描件等异构格式，利用视觉分析自动区分标题、正文、图片和表格区域，不依赖文档自身的格式标注。block 级输出展平后按语义分块——计算相邻句子的向量相似度，在相似度骤降处切开，分块粒度由语义边界决定而非固定字符数。章节拆分采用双策略：有标题结构的文档按标题层级预切后语义合并，无标题结构的文档直接全篇分块，同一套流程兼容两类文档。图片通过 OCR 提取文字替代，分块时通过句子到页码的映射关系追踪每个 chunk 在原始文档中的位置。

检索增强：采用 BM25 关键词检索 + BGE 向量语义检索双路召回，关键词匹配保证精确命中，向量语义保证泛化覆盖，召回结果经 BGE-Reranker 精排后取 top-K。LLM 选型考虑的是指令跟随能力而非推理能力——要求模型严格基于检索上下文生成回答，不添加上下文之外的信息，因此选用通义千问而非推理型模型。回答附带来源文档名和页码范围，方便用户回溯原文核查。

评测体系：建立三层人工+自动结合的评测机制。第一层离线回归——维护 50 条标注测试集，每次修改检索策略后自动跑关键词覆盖回归，纯向量计算无需 LLM 参与，保证改动不引入回归。第二层线上自动信号——监控空结果率、用户点踩率、重复提问率三个指标，超标自动标记触发人工审查。第三层人工抽查——每周从线上日志随机抽取 20 条，逐条验证检索质量和大模型回答正确性，对问题做归因分析和策略纠偏。

业绩:

用一套管线统一处理了多种异构文档格式（PDF/DOCX/PPTX/扫描件），通过语义分块替代固定长度分块，解决了不同格式文档的检索质量不一致问题

构建了混合检索 + 重排序的检索策略，关键词和语义互补减少了单一检索方式的漏召回

LLM 选型侧重指令跟随而非推理能力，有效减少了模型在检索上下文不足时的"脑补编造"问题

建立了三层评测体系，明确了 RAG 评测中自动化与人工的合理分工边界——自动信号用于缩小排查范围，人工抽查用于精准判断质量，不做虚假的全自动评测

离线回归测试保证了检索策略迭代的安全性，线上信号监控实现了问题的及时发现

空压机联控方案IOT平台

Java开发

2023.04-2024.04

内容:

项目背景：面向工业空压机集群运维管控，解决能耗高、协同效率低、人工调控不准的痛点，打造智能联控IoT平台

核心职责:

1. 主导系统从单体架构向微服务架构拆分，设计MySQL+Redis+HBase分层存储方案，优化设备元数据、热点数据、历史数据的存储性能

- 2. 基于Kafka+MQTT实现海量设备数据的削峰填谷，保障50+台空压机的实时数据采集与稳定传输
- 3. 搭建Nginx+Spring Gateway+Nacos+Sentinel+Seata高可用微服务架构，实现分布式锁、流量控制、分布式事务保障
- 4. 构建全链路可观测体系，通过SkyWalking+ELK实现链路追踪、日志监控与问题快速定位，采用Docker容器化部署上线

业绩：

- 1. 微服务拆分后，系统并发能力提升 3 倍，单服务故障不影响整体平台；
- 2. 引入Redis与本地缓存后，接口响应时间从 500ms 降至 60ms，性能提升 8 倍；
- 3. 实时数据处理吞吐量提升 200%，支撑单站点 50+ 台空压机的同时在线联控；
- 4. 缓存命中率达 92%，有效降低数据库与IoT设备接入压力；
- 5. 系统成功支撑工业客户 15%-30% 的节能降耗目标，运维成本降低 40%。

物联网管理平台场景化搭建

java开发

2022.06-2023.03

内容：

基于公司现有物联网管理平台，针对客户在真实生产环境中提出的特定需求，开展需求分析与定制化开发工作，实现平台功能的灵活适配与场景化落地。

业绩：

- 1. 作为后端技术接口人，协调前端、测试等多团队协作，将模糊业务需求转化为可落地的技术方案，通过敏捷开发模式推动项目按期上线。
- 2. 主导需求评审会议，组织技术方案讨论，确保方案具备可实施性与技术合理性。
- 3. 基于HTML5、JavaScript、jQuery、jQueryUi、Layui等前端技术完成表格、表单及图表等控件开发；采用Spring、SpringMVC、MyBatis、MySQL等后端技术实现核心业务逻辑开发。
- 4. 通过EMQX框架实现与硬件设备的通信，确保数据传输稳定高效；利用HBase与Redis完成硬件上传数据的存储与解析，提升系统响应速度与数据处理能力。

物联网管理平台前端优化

java开发

2022.01-2022.05

内容：

基于 Layui 进行物联网管理系统前端优化，使用 CSS/JavaScript 完成界面美化与交互逻辑开发，集成 ECharts 实现数据可视化图表展示，提升页面美观度、交互体验与数据呈现能力。

业绩：

- 1. 使用 Layui 重构页面，统一界面风格，优化表单、表格、弹窗等核心模块，提升整体美观度与易用性。
- 2. 通过 CSS 与原生 JS 优化交互逻辑与页面加载速度，修复兼容性问题，操作流畅度显著提升。
- 3. 基于 ECharts 实现折线图、柱状图、饼图等数据可视化，支持动态数据展示，提高数据分析效率。

英威腾工业物联网平台

Java开发

2021.05-2021.12

内容：

本项目旨在完成公司物联网系统需求池的开发与版本迭代，实现设备运行状态的实时监测、数据解析与计算、数据可视化展示、远程指令下发以及文件的上传下载功能。通过持续优化系统逻辑与交互流程，提升平台运行效率与稳定性，支持工业设备的智能化管理与远程控制需求。

业绩：

- 1. 参与英威腾工业物联网平台开发，负责后端接口全生命周期管理，包括需求分析、接口设计、功能实现及联调优化
- 2. 通过APIfox等工具提升接口开发效率与规范性，确保接口高可用性和兼容性，有效支撑业务快速落地
- 3. 在项目中持续优化接口性能，保障系统稳定运行，体现良好的开发能力和协作意识

教育经历

广东工业大学	硕士	仪器仪表工程	2017-2021
江西理工大学	本科	测控技术与仪器	2013-2017